

# 概率论与数理统计

## 第五章 概率极限定理

金玲飞

复旦大学软件学院  
Email: lfjin@fudan.edu.cn

2019.12.3

# 5.1 大数定律

- **大数定律：**大量重复试验所呈现的统计规律。“频率的稳定性”，“随机变量算数均值的稳定性”。
- 大数定律最早可追溯到公元1500年左右。
- 1713，Bernoulli正式提出并证明了最初的大数定律。
- 直到1930年，现在概率论奠基人Kolgomorov才真正证明了最后的强大数定律。

# 几种收敛性

## 定义 (5.1.1 依概率收敛)

设 $\{X_n : n = 1, 2, \dots\}$ 为随机变量序列,  $X$ 为随机变量。若对任意 $\epsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P(|X_n| > \epsilon) = 0$$

则称 $X_n$ 依概率收敛于0, 记为 $X_n \xrightarrow{P} 0$ 。

若 $X_n - X \xrightarrow{P} 0$ , 则称 $X_n$ 依概率收敛于 $X$ , 记为 $X_n \xrightarrow{P} X$ 。

# 几种收敛性

## 定义 (5.1.1 依概率收敛)

设 $\{X_n : n = 1, 2, \dots\}$ 为随机变量序列,  $X$ 为随机变量。若对任意 $\epsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P(|X_n| > \epsilon) = 0$$

则称 $X_n$ 依概率收敛于0, 记为 $X_n \xrightarrow{P} 0$ 。

若 $X_n - X \xrightarrow{P} 0$ , 则称 $X_n$ 依概率收敛于 $X$ , 记为 $X_n \xrightarrow{P} X$ 。

若 $X_n \xrightarrow{P} X$ ,  $g(x)$ 为连续函数, 则 $g(X_n) \xrightarrow{P} g(X)$ 。

### 定义 (5.1.2 按分布收敛)

设随机变量  $X, X_1, X_2, \dots$  的分布函数分别为  $F(x), F_1(x), F_2(x), \dots$ 。若对  $F(x)$  的任一连续点  $x$ , 都有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

则称  $\{F_n(x)\}$  弱收敛于  $F(x)$ , 记为  $F_n(x) \xrightarrow{w} F(x)$ 。

也称  $\{X_n\}$  按分布收敛于  $X$ , 记为  $X_n \xrightarrow{L} X$ 。

### 定义 (5.1.3 几乎必然收敛 Almost sure convergence)

设 $X, X_n (n = 1, 2, \dots)$ 均为 $(\Omega, \mathcal{F}, P)$ 上的随机变量。若

$$P(\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)) = 1$$

则称 $X_n$ 几乎必然收敛于 $X$ ，记为 $X_n \xrightarrow{a.s.} X$ ，  
或 $X_n \rightarrow X$  a.s.。

设 $X, X_n (n = 1, 2, \dots)$ 均为 $(\Omega, \mathcal{F}, P)$ 上的随机变量。则

$$X_n \xrightarrow{\text{a.s.}} X \Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{L} X$$



### 定义 (5.1.4)

- 若 $X_1, \dots, X_n$ 相互独立, 则称 $\{X_n : n = 1, 2, \dots\}$ 为独立随机变量序列
- 若 $X_1, \dots, X_n$ 相互独立且具有相同的分布函数, 则称 $\{X_n : n = 1, 2, \dots\}$ 为独立同分布随机变量序列

# 常用的几个大数定律

## 切比雪夫大数定律

### 定理 (5.1.1 Chebyshev law of large numbers)

设 $\{X_n : n = 1, 2, \dots\}$ 为独立随机变量序列。若存在常数 $C$ ，使得 $D(X_n) \leq C, n = 1, 2, \dots$ ，则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k) \right| > \epsilon \right) = 0 \quad (1)$$

即

$$\frac{1}{n} \sum_{k=1}^n (X_k - E(X_k)) \xrightarrow{P} 0$$

- 若随机变量序列 $\{X_n : n = 1, 2, \dots\}$ 满足(1)式, 则称它服从大数定律。

- 若随机变量序列 $\{X_n : n = 1, 2, \dots\}$ 满足(1)式, 则称它服从大数定律。
- 在什么条件下,  $\{X_n : n = 1, 2, \dots\}$ 服从大数定律?

## 推论 (5.1.2)

如果 $\{X_n : n = 1, 2, \dots\}$ 是独立同分布的, 期望 $E(X_n) = \mu$ , 方差 $D(X_n) = \sigma^2$ , 则有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| > \epsilon \right) = 0$$

即

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

## 推论 (5.1.2)

如果 $\{X_n : n = 1, 2, \dots\}$ 是独立同分布的, 期望 $E(X_n) = \mu$ , 方差 $D(X_n) = \sigma^2$ , 则有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| > \epsilon \right) = 0$$

即

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$$

- 算术均值的稳定性: 当试验次数 $n \rightarrow \infty$ , 平均值 $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛于期望。

### 例子 (5.1.1)

设  $\{X_n : n = 1, 2, \dots\}$  是相互独立的随机变量序列。若

$$P(X_n = -3^n) = P(X_n = 3^n) = 3^{-(2n+2)}$$

$$P(X_n = 0) = 1 - \frac{2}{3^{2n+2}}$$

问此随机变量序列是否服从大数定律？

### 例子 (5.1.2)

设  $\{X_n : n = 1, 2, \dots\}$  是独立同分布的随机变量序列,  $E(X_n^4) < \infty$ 。若令  $E(X_n) = \mu, D(X_n) = \sigma^2$ 。考察

$$Y_n = (X_n - \mu)^2, n = 1, 2, \dots,$$

则  $\{Y_n : n = 1, 2, \dots\}$  是否服从大数定律。



# 伯努利大数定律

最早提出的大数定律是1713年伯努利大数定律。

## 定理 (5.1.3 Bernoulli law of large numbers)

设 $n_A$ 为 $n$ 重伯努利试验中事件 $A$ 发生的次数，又 $A$ 在每次试验中发生的概率为 $p(0 < p < 1)$ ，则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| < \epsilon\right) = 1$$

# 伯努利大数定律

最早提出的大数定律是1713年伯努利大数定律。

## 定理 (5.1.3 Bernoulli law of large numbers)

设 $n_A$ 为 $n$ 重伯努利试验中事件 $A$ 发生的次数，又 $A$ 在每次试验中发生的概率为 $p(0 < p < 1)$ ，则对任意 $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{n_A}{n} - p\right| < \epsilon\right) = 1$$

- 抛一枚硬币 $10^4$ 次， $n = 10^4$ 。设 $\epsilon = 0.01$ ，

$$P\left(\left|\frac{n_A}{n} - 0.5\right| > 0.01\right) \leq \frac{10^4}{4n}$$

# 辛钦大数定律

可否去掉方差存在的条件？

定理 (5.1.4 辛钦大数定律)

设  $\{X_n : n = 1, 2, \dots\}$  是独立同分布随机变量序列， $E(X_n) = \mu$ 。则对任意的  $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| > \epsilon \right) = 0$$

即

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

# 辛钦大数定律

可否去掉方差存在的条件？

## 定理 (5.1.4 辛钦大数定律)

设  $\{X_n : n = 1, 2, \dots\}$  是独立同分布随机变量序列， $E(X_n) = \mu$ 。则对任意的  $\epsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| > \epsilon \right) = 0$$

即

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

辛钦大数定律提供了求期望  $E(X)$  的近似值的方法。

# Strong law of large numbers

定理 (5.1.5 科尔莫戈罗夫强大数定律)

设  $\{X_n : n = 1, 2, \dots\}$  是独立同分布的随机变量序列,  $E(X_n) = \mu$ , 则

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{a.s.} \mu$$

### 定理 (5.1.6 博雷尔强大数定律)

设 $n_A$ 为 $n$ 重伯努利试验中事件 $A$ 发生的次数，又 $A$ 在每次试验中发生的概率为 $p(0 < p < 1)$ ，则

$$\frac{n_A}{n} \xrightarrow{\text{a.s.}} p$$

### 例子 (5.1.3 蒙特卡罗方法计算积分)

设 $g(x)$ 在区间 $[0, 1]$ 上绝对可积，试计算积分 $\int_0^1 g(x)dx$ 。

### 例子 (5.1.3 蒙特卡罗方法计算积分)

设 $g(x)$ 在区间 $[0, 1]$ 上绝对可积, 试计算积分 $\int_0^1 g(x)dx$ 。

- 设 $X$  是服从 $[0, 1]$ 上的均匀分布。
- $Y = g(X)$ 的数学期望 $E(Y) = \int_0^1 g(x)dx = J$ 。
- 根据辛钦大数定律, 可以用 $g(X)$ 的观察值的平均值去估计它的期望。



### 例子 (5.1.3 蒙特卡罗方法计算积分)

设 $g(x)$ 在区间 $[0, 1]$ 上绝对可积, 试计算积分 $\int_0^1 g(x)dx$ 。

- 设 $X$  是服从 $[0, 1]$ 上的均匀分布。
- $Y = g(X)$ 的数学期望 $E(Y) = \int_0^1 g(x)dx = J$ 。
- 根据辛钦大数定律, 可以用 $g(X)$ 的观察值的平均值去估计它的期望。

先用计算机产生 $n$ 个均匀分布的随机数 $x_i$ , 再计算 $g(x_i)$ 。

## 5.2 中心极限定理

# 中心极限定理

设 $\{X_n : n = 1, 2, \dots\}$ 是独立随机变量序列，当 $n$ 很大时，研究

$$Y_n = X_1 + X_2 + \dots + X_n$$

的分布？

# 中心极限定理

设 $\{X_n : n = 1, 2, \dots\}$ 是独立随机变量序列，当 $n$ 很大时，研究

$$Y_n = X_1 + X_2 + \dots + X_n$$

的分布？

$$Y_n^* = \frac{Y_n - E(Y_n)}{\sqrt{D(Y_n)}}$$

- 在某种条件下，使得随机变量序列的和的极限分布是正态分布的结果，统称为**中心极限定理**。

### 定理 (5.2.1 莱维-林德伯格中心极限定理)

设  $\{X_n : n = 1, 2, \dots\}$  是独立同分布随机变量序列,  $E(X_n) = \mu$ ,  $D(X_n) = \sigma^2 > 0$ 。则随机变量

$$\frac{1}{\sqrt{n}\sigma} \left( \sum_{k=1}^n X_k - n\mu \right)$$

的分布函数  $F_n(x)$  收敛到标准正态分布函数  $\Phi(x)$ , 即对任意实数  $x$ , 成立

$$\lim_{n \rightarrow \infty} P \left( \frac{1}{\sqrt{n}\sigma} \left( \sum_{k=1}^n X_k - n\mu \right) \leq x \right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

### 定义 (5.2.1)

当随机变量序列的极限分布是正态分布时，我们也称该随机变量序列是渐近正态分布的。

### 定义 (5.2.1)

当随机变量序列的极限分布是正态分布时，我们也称该随机变量序列是渐近正态分布的。

### 例子 (5.2.1 误差估计)

计算机在进行数字计算时，遵从四舍五入的原则。为简单计，现对小事实数点后面第一位进行舍入运算，则误差 $X$ 可以认为服从均匀分布 $U[-0.5, 0.5]$ 。若在一项计算中进行了100次数字计算，求平均误差落在区间 $\left[-\frac{\sqrt{3}}{20}, \frac{\sqrt{3}}{20}\right]$ 上的概率。

### 例子 (5.2.2 正态随机数的产生)

在随机模拟（蒙特卡洛方法）中经常需要产生正态分布  $N(\mu, \sigma^2)$  的随机数，一般的统计软件都没有产生正态随机数的功能。那如何产生的呢？



### 例子 (5.2.2 正态随机数的产生)

在随机模拟（蒙特卡洛方法）中经常需要产生正态分布 $N(\mu, \sigma^2)$ 的随机数，一般的统计软件都没有产生正态随机数的功能。那如何产生的呢？

其中一种方法：用中心极限定理通过 $(0, 1)$ 上的均匀分布的随机数来产生正态分布 $N(\mu, \sigma^2)$ 的随机数。

# 拉普拉斯极限定理

## 二项分布的正态近似

### 定理 (5.2.2 棣莫弗-拉普拉斯极限定理)

设 $n_A$ 为 $n$ 重伯努利试验中事件 $A$ 出现的次数, 又 $A$ 在每次试验中发生的概率为 $p(0 < p < 1)$ 。则对任意实数 $x$ , 有

$$\lim_{n \rightarrow \infty} P\left(\frac{n_A - np}{\sqrt{np(1-p)}} \leq x\right) = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

### 推论 (5.2.3)

上面定理表明，二项分布可以用正态分布来近似。即对  $a \leq b$ ，有

$$\begin{aligned} P(a \leq n_A \leq b) \\ &= P\left(\frac{a - np}{\sqrt{np(1-p)}} \leq \frac{n_A - np}{\sqrt{np(1-p)}} \leq \frac{b - np}{\sqrt{np(1-p)}}\right) \\ &\approx \Phi\left(\frac{b - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - np}{\sqrt{np(1-p)}}\right) \end{aligned}$$

## 我们做如下修正来提高精度

- 由于 $n_A$ 只取整数, 故对整数 $a, b$ 和任意 $0 \leq \epsilon_1, \epsilon_2 < 1$ , 有

$$\begin{aligned} P(a \leq n_A \leq b) &= P(a - \epsilon_1 \leq n_A \leq b + \epsilon_2) \\ &\approx \Phi\left(\frac{b + \epsilon_2 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - \epsilon_1 - np}{\sqrt{np(1-p)}}\right) \end{aligned}$$

## 我们做如下修正来提高精度

- 由于 $n_A$ 只取整数，故对整数 $a, b$ 和任意 $0 \leq \epsilon_1, \epsilon_2 < 1$ ，有

$$\begin{aligned} P(a \leq n_A \leq b) &= P(a - \epsilon_1 \leq n_A \leq b + \epsilon_2) \\ &\approx \Phi\left(\frac{b + \epsilon_2 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - \epsilon_1 - np}{\sqrt{np(1-p)}}\right) \end{aligned}$$

- 进一步分析表明，选择 $\epsilon_1 = \epsilon_2 = 0.5$ 得到的修正公式效果较好，

$$P(a \leq n_A \leq b) \approx \Phi\left(\frac{b + 0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - 0.5 - np}{\sqrt{np(1-p)}}\right)$$

- 对二项分布的计算，用修正的正态分布还可以近似求得

$$P(n_A = b) = P(b - 0.5 < n_A < b + 0.5)$$

比如  $n_A \sim b(25, 0.4)$ ，则  $P(n_A = 10) = 0.1612$ ，而用正态近似估计可得  $P(n_A = 10) = 0.1629$ 。

利用中心极限定理可以解决三种计算问题：

$$P(Y_n^* \leq y) \approx \Phi(y) = \beta$$

- ① 已知 $n, y$ , 求 $\beta$ ;
- ② 已知 $n, \beta$ , 求 $y$ ;
- ③ 已知 $\beta, y$ , 求 $n$ ;

### 例子 (5.2.3)

一复杂系统由 **100** 个相互独立工作的部件组成，每个部件正常工作的概率为 **0.9**。已知整个系统中至少要有 **85** 个部件正常工作，系统才能正常工作。求该系统正常工作的概率。



### 例子 (5.2.3)

一复杂系统由**100**个相互独立工作的部件组成，每个部件正常工作的概率为**0.9**。已知整个系统中至少要有**85**个部件正常工作，系统才能正常工作。求该系统正常工作的概率。

### 例子 (5.2.4)

某单位有**260**部电话，每部电话约有**4%**的时间要使用外线通话。设每部电话是否使用外线是相互独立的，问该单位总机至少需要安装多少条外线，才能以**95%**以上的概率保证每部电话需要使用外线时可以打通？

### 例子 (5.2.5)

某厂生产的螺丝钉的不合格品率为 $0.01$ .问一盒中应至少装多少只螺丝钉才能保证其中含有 $100$ 只合格品的概率不小于 $0.95$ ?

### 例子 (5.2.6)

电视台做某节目A收视率的调查，在每天节目A播出时随机地向当地居民打电话，问是否在看电视，如在，再问是否在看节目A。设回答在看电视的居民数位 $n$ ，为保证以95%的概率使调查误差不超过10%，问 $n$ 至少应取多大？

- 当 $n$ 很大时,  $\frac{1}{\sqrt{n}\sigma} (\sum_{k=1}^n X_k - n\mu)$  的分布函数 $F_n(x)$ 收敛于标准正态分布 $\Phi(x)$ 。那么 $F_n(x)$ 收敛于 $\Phi(x)$  的速度怎样?

- 当 $n$ 很大时,  $\frac{1}{\sqrt{n}\sigma} (\sum_{k=1}^n X_k - n\mu)$  的分布函数 $F_n(x)$ 收敛于标准正态分布 $\Phi(x)$ 。那么 $F_n(x)$ 收敛于 $\Phi(x)$  的速度怎样?

### 定理 (Berry-Esseen Theorem)

设 $\{X_n : n = 1, 2, \dots\}$ 是独立同分布随机变量序列,  $E(X_n) = \mu$ ,  $D(X_n) = \sigma^2 > 0$ ,  $E(|X_1 - \mu|^3) = \rho < \infty$ 。则对任意的实数 $x$ 和任意 $n \geq 1$ ,

$$|P(\frac{1}{\sqrt{n}\sigma} (\sum_{k=1}^n X_k - n\mu) \leq x) - \Phi(x)| \leq \frac{3\rho}{\sigma^3 \sqrt{n}}$$

- 
- 独立同分布随机变量序列的中心极限定理
    - (1) 林德贝格—勒维中心极限定理
    - (2) 棣莫弗—拉普拉斯中心极限定理
  - 独立不同分布随机变量序列的中心极限定理
    - (1) 林德贝格中心极限定理
    - (2) 李雅普诺夫中心极限定理
-

# 中心极限定理

- 若 $\{X_n\}$ 服从中心极限定理，则 $\{X_n \pm a_n\}$ 也服从中心极限定理，其中 $\{a_n\}$ 为常数列。

# 中心极限定理

- 若 $\{X_n\}$ 服从中心极限定理，则 $\{X_n \pm a_n\}$ 也服从中心极限定理，其中 $\{a_n\}$ 为常数列。

## 例子

用概率的方法证明

$$\lim_{n \rightarrow \infty} \left(1 + n + \frac{n^2}{2!} + \cdots + \frac{n^n}{n!}\right) e^{-n} = \frac{1}{2}$$



# 中心极限定理

- 若 $\{X_n\}$ 服从中心极限定理，则 $\{X_n \pm a_n\}$ 也服从中心极限定理，其中 $\{a_n\}$ 为常数列。

## 例子

用概率的方法证明

$$\lim_{n \rightarrow \infty} (1 + n + \frac{n^2}{2!} + \cdots + \frac{n^n}{n!}) e^{-n} = \frac{1}{2}$$

设 $\{X_n\}$ 是独立同分布的随机变量序列，服从 $P(1)$ 。 $E(X_n) = D(X_n) = 1$ 。根据可加性， $Y_n = \sum_{i=1}^n X_i \sim P(n)$ 。

# 中心极限定理

- 若 $\{X_n\}$ 服从中心极限定理，则 $\{X_n \pm a_n\}$ 也服从中心极限定理，其中 $\{a_n\}$ 为常数列。

## 例子

用概率的方法证明

$$\lim_{n \rightarrow \infty} (1 + n + \frac{n^2}{2!} + \cdots + \frac{n^n}{n!}) e^{-n} = \frac{1}{2}$$

设 $\{X_n\}$ 是独立同分布的随机变量序列，服从 $P(1)$ 。 $E(X_n) = D(X_n) = 1$ 。根据可加性， $Y_n = \sum_{i=1}^n X_i \sim P(n)$ 。根据林德伯格-莱维中心极限定理

$$P\left(\frac{Y_n - n}{\sqrt{n}} \leq 0\right) = P(Y_n \leq n)$$