

概率论与数理统计

第七章 参数估计


金玲飞

复旦大学软件学院
Email: lfjin@fudan.edu.cn

2018.12.11

参数估计的基本思想

参数估计：用所获得的样本值去估计参数取值。



目录

- 点估计（矩估计，极大似然估计）
- 估计量的评判标准
- 区间估计
- 正态总体均值与方差的区间估计

7.1 点估计

已知分布类型 $F(x; \theta)$ ，但是 θ 未知。

- 参数空间： Θ ，参数 $\theta \in \Theta$ 。

已知分布类型 $F(x; \theta)$ ，但是 θ 未知。

- **参数空间**: Θ ，参数 $\theta \in \Theta$ 。
- **估计量(estimator)**: 用于估计总体参数的随机变量。
记 $\hat{\theta}$
 - **EX**: 样本均值就是总体均值 μ 的一个估计量。
- **估计值(estimated value)**: 估计参数时计算出来的统计量的具体值。

点估计

定义 (7.1.1)

设总体 X 的分布函数为 $F(x; \theta)$ ，未知参数 $\theta \in \Theta$ ， X_1, X_2, \dots, X_n 是来自总体 X 的样本， x_1, x_2, \dots, x_n 是样本观测值。选取一个统计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 来估计 θ 。我们称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的**点估计量**， $\hat{\theta}(x_1, x_2, \dots, x_n)$ 是 θ 的**点估计值**。

点估计

定义 (7.1.1)

设总体 X 的分布函数为 $F(x; \theta)$ ，未知参数 $\theta \in \Theta$ ， X_1, X_2, \dots, X_n 是来自总体 X 的样本， x_1, x_2, \dots, x_n 是样本观测值。选取一个统计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 来估计 θ 。我们称 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的**点估计量**， $\hat{\theta}(x_1, x_2, \dots, x_n)$ 是 θ 的**点估计值**。

如何选取合适的统计量来估计参数？

矩估计法—1900年由K. Pearson提出

- 设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$, 有 k 个未知参数 $\theta_1, \dots, \theta_k$ 。 X_1, X_2, \dots, X_n 是来自总体 X 的样本, x_1, x_2, \dots, x_n 是样本观测值。设总体 X 的矩 $E(X^k)$ 存在, 此时所有低阶矩均存在。

矩估计法—1900年由K. Pearson提出

- 设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$, 有 k 个未知参数 $\theta_1, \dots, \theta_k$ 。 X_1, X_2, \dots, X_n 是来自总体 X 的样本, x_1, x_2, \dots, x_n 是样本观测值。设总体 X 的矩 $E(X^k)$ 存在, 此时所有低阶矩均存在。
- **原理:** 当 n 较大是, 样本 k 阶原点矩依概率收敛到总体 k 阶矩。
- **矩法估计:** "替换"。用样本矩来代替总体矩, 从而得到总体分布中的参数的一种估计。

矩估计法 moment estimate

- ① 计算 $E(X^j), j = 1, \dots, k$, 得到含有未知参数 $\theta_1, \dots, \theta_k$ 的 k 个方程。

$$E(X^j) = g_j(\theta_1, \dots, \theta_k), j = 1, \dots, k$$

- ② 近似替换, 列出方程组

$$\begin{cases} g_1(\theta_1, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i \\ g_2(\theta_1, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^2 \\ \dots\dots\dots \\ g_k(\theta_1, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^k \end{cases}$$

- ③ 解方程组, 得到 $\theta_1, \dots, \theta_k$ 的一组解, $\hat{\theta}_j = \hat{\theta}_j(X_1, X_2, \dots, X_n)$ 。

用矩法得到的估计量 $\hat{\theta}_j(X_1, X_2, \dots, X_n)$ 称为 $\hat{\theta}_j$ 的矩估计量
Moment estimator。估计值 $\hat{\theta}_j(x_1, x_2, \dots, x_n)$ 称为 $\hat{\theta}_j$ 的矩估计值。

用矩法得到的估计量 $\hat{\theta}_j(X_1, X_2, \dots, X_n)$ 称为 $\hat{\theta}_j$ 的矩估计量 **Moment estimator**。估计值 $\hat{\theta}_j(x_1, x_2, \dots, x_n)$ 称为 $\hat{\theta}_j$ 的矩估计值。

矩法的优点：精髓是替换，计算简便。当样本容量 n 很大时，矩估计接近被估计参数的真值的概率很大。

用矩法得到的估计量 $\hat{\theta}_j(X_1, X_2, \dots, X_n)$ 称为 $\hat{\theta}_j$ 的矩估计量 **Moment estimator**。估计值 $\hat{\theta}_j(x_1, x_2, \dots, x_n)$ 称为 $\hat{\theta}_j$ 的矩估计值。

矩法的优点：精髓是替换，计算简便。当样本容量 n 很大时，矩估计接近被估计参数的真值的概率很大。

矩法的缺点：

- 要求期望存在。
- 矩估计不唯一(尽量使用低阶矩)。

例子 (7.1.1)

设总体 $X \sim B(m, p)$, 其中 m 已知, $p(0 < p < 1)$ 是未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 p 的矩估计量。

例子 (7.1.1)

设总体 $X \sim B(m, p)$, 其中 m 已知, $p (0 < p < 1)$ 是未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 p 的矩估计量。

例子 (7.1.2)

设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 是未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 μ, σ^2 的矩估计量。

例子 (7.1.3)

设总体 $X \sim U[0, \theta]$, $\theta > 0$ 是未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 θ 的矩估计量。

例子 (7.1.3)

设总体 $X \sim U[0, \theta]$, $\theta > 0$ 是未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 θ 的矩估计量。

- 若 $X \sim U[a, b]$ 呢?

例子 (7.1.3)

设总体 $X \sim U[0, \theta]$, $\theta > 0$ 是未知参数, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 θ 的矩估计量。

- 若 $X \sim U[a, b]$ 呢?

$$\hat{a} = \bar{X} - \sqrt{3}S, \quad \hat{b} = \bar{X} + \sqrt{3}S,$$

最大似然估计法

最大似然估计法: 在总体类型已知的条件下使用的一种参数估计方法。

首先是由**高斯**(Gauss)在1821年提出。



费希尔(Fisher)在1912年重新发现了这个方法，并证明了一些性质



最大似然原理

最大似然原理: 如果在一次随机试验中结果A发生，而导致A发生的原因有很多。在分析导致A发生的原因时，使结果A发生的概率最大的原因，推断为导致A发生的原因。

最大似然原理

最大似然原理: 如果在一次随机试验中结果**A**发生，而导致**A**发生的原因有很多。在分析导致**A**发生的原因时，使结果**A**发生的概率最大的原因，推断为导致**A**发生的原因。

例子 (7.1.4)

设有外形完全相同的两个箱子，甲箱有**99**个白球和**1**个黑球，乙箱有**1**个白球和**99**个黑球，今随机地抽取一箱，然后再从这箱中任取一球，结果发现是白球，问这球是从哪一个箱子中取出的？

设总体 X 的分布类型已知，但含有未知参数 θ 。

定义 (7.1.2 似然函数 Likelihood function)

设 X_1, X_2, \dots, X_n 是来自总体 X 的样本， x_1, x_2, \dots, x_n 是样本观察值。令

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \begin{cases} \prod_{i=1}^n p(x_i; \theta) & \text{离散型} \\ \prod_{i=1}^n f(x_i; \theta) & \text{连续型} \end{cases}$$

称 $L(\theta)$ 为似然函数。

设总体 X 的分布类型已知，但含有未知参数 θ 。

定义 (7.1.2 似然函数 Likelihood function)

设 X_1, X_2, \dots, X_n 是来自总体 X 的样本， x_1, x_2, \dots, x_n 是样本观察值。令

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \begin{cases} \prod_{i=1}^n p(x_i; \theta) & \text{离散型} \\ \prod_{i=1}^n f(x_i; \theta) & \text{连续型} \end{cases}$$

称 $L(\theta)$ 为似然函数。

注：似然函数与联合分布一样吗？

最大似然法

- 将 θ 看成原因， (x_1, \dots, x_n) 看成结果。
- **最大似然法：** 寻找参数值 $\hat{\theta}(x_1, \dots, x_n)$ 使得当 $\theta = \hat{\theta}(x_1, \dots, x_n)$ 时出现样本观察值 (x_1, \dots, x_n) 的可能性最大。

最大似然法

- 将 θ 看成原因， (x_1, \dots, x_n) 看成结果。
- **最大似然法**：寻找参数值 $\hat{\theta}(x_1, \dots, x_n)$ 使得当 $\theta = \hat{\theta}(x_1, \dots, x_n)$ 时出现样本观察值 (x_1, \dots, x_n) 的可能性最大。

定义 (7.1.3 Maximum likelihood estimate)

设 $L(\theta) = L(\theta; x_1, \dots, x_n)$ 是似然函数，若存在 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ ，使得

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$$

则称 $\hat{\theta}(x_1, \dots, x_n)$ 是未知参数 θ 的**最大似然估计值**，称 $\hat{\theta}(X_1, \dots, X_n)$ 是未知参数 θ 的**最大似然估计量**。

如何求 $L(\theta)$ 的最大值点？

如何求 $L(\theta)$ 的最大值点？

如何求 $L(\theta)$ 的最大值点？

如何求 $L(\theta)$ 的最大值点？

- 若似然函数 $L(\theta)$ 关于 θ 可导，令

$$\frac{dL(\theta)}{d\theta} = 0$$

解此方程得 θ 的最大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 。

如何求 $L(\theta)$ 的最大值点？

如何求 $L(\theta)$ 的最大值点？

- 若似然函数 $L(\theta)$ 关于 θ 可导，令

$$\frac{dL(\theta)}{d\theta} = 0$$

解此方程得 θ 的最大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 。

- $L(\theta)$ 与 $\ln L(\theta)$ 具有相同的最大值点，令

$$\frac{d\ln L(\theta)}{d\theta} = 0$$

解此方程得 θ 的最大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 。

最大似然估计的一般步骤归纳如下：

(1) 求似然函数 $L(\theta)$ ；

(2) 求出 $\ln L(\theta)$ 并整理；

(3) 求似然方程组 $\frac{\partial}{\partial \theta} \ln L(\theta) = 0$ ；

(3) 解上述方程得最大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 或最大似然估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 。

例子 (7.1.5)

设总体 $X \sim B(m, p)$ ，其中 m 已知， p 为未知参数， X_1, \dots, X_n 是来自 X 的样本， x_1, \dots, x_n 是样本观察值，求 p 的最大似然估计量。

例子 (7.1.5)

设总体 $X \sim B(m, p)$ ，其中 m 已知， p 为未知参数， X_1, \dots, X_n 是来自 X 的样本， x_1, \dots, x_n 是样本观察值，求 p 的最大似然估计量。

p 的最大似然估计量是 $\frac{\bar{X}}{m}$ 。

例子 (7.1.7)

设总体 $X \sim N(\mu, \sigma^2)$, X_1, \dots, X_n 是来自 X 的样本, x_1, x_2, \dots, x_n 是样本观察值, 求 μ, σ^2 的最大似然估计量。

例子 (7.1.7)

设总体 $X \sim N(\mu, \sigma^2)$, X_1, \dots, X_n 是来自 X 的样本, x_1, x_2, \dots, x_n 是样本观察值, 求 μ, σ^2 的最大似然估计量。

例子 (7.1.8)

设总体 X 服从 $[0, \theta]$ 上的均匀分布, $\theta > 0$ 是未知参数, X_1, \dots, X_n 是来自 X 的样本, x_1, \dots, x_n 是样本观察值, 求 θ 的最大似然估计值。

例子 (7.1.7)

设总体 $X \sim N(\mu, \sigma^2)$, X_1, \dots, X_n 是来自 X 的样本, x_1, x_2, \dots, x_n 是样本观察值, 求 μ, σ^2 的最大似然估计量。

例子 (7.1.8)

设总体 X 服从 $[0, \theta]$ 上的均匀分布, $\theta > 0$ 是未知参数, X_1, \dots, X_n 是来自 X 的样本, x_1, \dots, x_n 是样本观察值, 求 θ 的最大似然估计值。

θ 的最大似然估计值是 $\hat{\theta} = \max\{x_1, \dots, x_n\}$

- 最大似然估计不一定唯一。

不变性

- 若 $\hat{\theta}$ 是总体分布中未知参数 θ 的最大似然估计, 则 $g(\hat{\theta})$ 是否仍是 $g(\theta)$ 的最大似然估计?

不变性

- 若 $\hat{\theta}$ 是总体分布中未知参数 θ 的最大似然估计, 则 $g(\hat{\theta})$ 是否仍是 $g(\theta)$ 的最大似然估计?

性质 (7.1.4 最大似然估计的不变性)

设 $g(\theta)$ 是单射, 若 $\hat{\theta}$ 是总体分布中未知参数 θ 的最大似然估计, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的最大似然估计。

表 7.1 常见分布中参数的估计量

分布	矩估计	最大似然估计	性质
两点分布 $B(1, p)$	$\hat{p} = \bar{X}$	$\hat{p} = \bar{X}$	有效估计, 相合估计
二项分布 $B(N, p)$	$\hat{p} = \frac{\bar{X}}{N}$	$\hat{p} = \frac{\bar{X}}{N}$	无偏估计, 相合估计
泊松分布 (参数 λ)	$\hat{\lambda} = \bar{X}$	$\hat{\lambda} = \bar{X}$	有效估计, 相合估计
正态分布 $N(\mu, \sigma^2)$	$\hat{\mu} = \bar{X}$ $\hat{\sigma}^2 = \frac{n-1}{n} S^2$ $\hat{\sigma} = \sqrt{\frac{n-1}{n}} S$	$\hat{\mu} = \bar{X}$ $\hat{\sigma}^2 = \frac{n-1}{n} S^2$ $\hat{\sigma} = \sqrt{\frac{n-1}{n}} S$	$\hat{\mu} = \bar{X}$ 是 μ 的有效、相合估计; S^2 为 σ^2 的渐近有效估计, 一致最小方差无偏估计; 相合估计; S 为 σ 的相合估计, 有偏估计
正态分布 $N(\mu, \sigma_0^2)$ (σ_0^2 已知)	$\hat{\mu} = \bar{X}$	$\hat{\mu} = \bar{X}$	有效估计, 相合估计
正态分布 $N(\mu_0, \sigma^2)$ (μ_0 已知)	$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2$	$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2$	有效估计, 相合估计
指数分布 (参数 λ) (记 $\theta = \frac{1}{\lambda}$)	$\hat{\lambda} = \frac{1}{\bar{X}}$ $\hat{\theta} = \bar{X}$	$\hat{\lambda} = \frac{1}{\bar{X}}$ $\hat{\theta} = \bar{X}$	$\hat{\lambda} = \frac{1}{\bar{X}}$ 是 λ 的相合估计, $\frac{1}{\bar{X}} - \frac{1}{n\bar{X}}$ 是 λ 的一致最小方差无偏估计, 相合估计; $\hat{\theta} = \bar{X}$ 是 θ 的有效、相合估计
均匀分布 $U(0, \theta)$	$\hat{\theta} = 2\bar{X}$	$\hat{\theta} = \max_{1 \leq i \leq n} X_i$	$2\bar{X}$ 是 θ 的无偏、相合估计; $\frac{n+1}{n} \max_{1 \leq i \leq n} X_i$ 是 θ 的一致最小方差无偏估计, 相合估计
均匀分布 $U(a, b)$	$\hat{a} = \bar{X} - \sqrt{3} \sqrt{\frac{n-1}{n}} S$ $\hat{b} = \bar{X} + \sqrt{3} \sqrt{\frac{n-1}{n}} S$	$\hat{a} = \min_{1 \leq i \leq n} X_i$ $\hat{b} = \max_{1 \leq i \leq n} X_i$	相合估计, 有偏估计